

NILA AI

The You Who Made It

Обновлённый план Telegram MVP
с учётом voice-first интервью, Future You и health-data слоя

8 недель • 14 июля - 4 сентября 2026
Core WOW MVP готов после Week 4

WOW #1	WOW #2	WOW #3
не квиз, а адаптивное эмоциональное интервью	через 60-90 минут приходит The You Who Made It	через ~48 часов Future You возвращается с одним мягким действием

Главное изменение относительно плана v0.1

Не начинаем с wearables и анализов

Первые четыре недели доказывают уникальную петлю продукта без внешних данных: голосовое интервью → структурированное понимание → Future You → проактивное действие через 48 часов. Wearables, labs, genome и agents усиливают уже доказанный experience, а не являются входным барьером.

Примечание: под «Cloud Code» в плане понимается Claude Code. Если имелся в виду Google Cloud Code, пользовательские срезы и даты не меняются; меняется только deployment workflow.

1. Что меняем в старом плане

Новый концепт требует переставить приоритеты: сначала доказать эмоциональную уникальность, потом добавлять health-data intelligence.

W	Даты	Релиз	Что пользователь видит
1	14-17 Jul	Telegram + adaptive voice interview	Рабочее интервью из voice/text; каждый вопрос удерживает предыдущий контекст.
2	20-24 Jul	Interview quality + hidden completeness	Система тонко собирает обязательные health-факты и строит профиль, который можно исправить.
3	27-31 Jul	The You Who Made It	Selfie → реалистичный same-age avatar → персональное сообщение через 60-90 минут.
4	3-7 Aug	48-hour best-friend loop + NMS	Future You возвращается, помнит историю и предлагает одно посильное действие.
5	10-14 Aug	Optional health-data intake	Labs, current stack и ограниченный genome intake усиливают профиль, но не блокируют продукт.
6	17-21 Aug	Wearable Gateway v1	WHOOP + единая модель метрик; proactivity становится data-aware.
7	24-28 Aug	Specialist agents + evidence + doctor handoff	Гипотеза по БАДу/пептиду получает evidence, возражения и clinician gate.
8	31 Aug-4 Sep	Closed loop + hardening	Действие → feedback/data → пересмотр; метрики, стоимость, removal test, решение о следующем этапе.

Две точки готовности

Core WOW MVP - после Week 4

Можно внутренне проверить уникальность идеи без WHOOP, Apple Watch, анализов или генома. Пользователь уже проходит интервью, получает Future You и 48-hour action.

Data-enriched MVP - после Week 8

К тому же experience добавлены labs/genome/stack, wearable proactivity, specialist agents, doctor handoff и замкнутый outcome loop.

Ключевой продуктовый принцип

- Интервью длится ориентировочно 10-20 минут, а окно 0-3 часа включает интервью, паузу и reveal. Не заставляем человека говорить три часа.
- Voice-first, но всегда остаётся кнопка «Answer by text» и «Skip this question».
- Future You говорит из личной истории, но каждый health-совет отделяет: что человек сказал, что показывают данные и что ещё нужно проверить.
- Проактивность - не количество уведомлений. Один точный контакт лучше пяти "умных" напоминаний.

2. Архитектура MVP

Один backend Neoly/Nila AI, одна БД, отдельный wellness-модуль. Telegram - интерфейс, Claude Code - инструмент разработки, а не runtime-архитектура.

Runtime pipeline первой сессии

Слой	Результат
1. Telegram	voice / text / selfie / document
2. Speech layer	audio → transcript + confidence + medical glossary
3. State updater	facts + narrative threads + contradictions + missing required fields
4. Interviewer	один следующий вопрос, основанный на открытой нити предыдущего ответа
5. Profile synthesizer	“кем хочет быть” + препятствия + health facts + uncertainty
6. Future You	same-age image + first-person message; raw transcript в image API не отправляется
7. Durable scheduler	60-90 min reveal и 48h proactive message переживают restart/deploy
8. Action loop	one gentle NMS action → done / later / not for me → adaptation

Почему одного “опытного AI-промпта” недостаточно

Разделяем извлечение и разговор

После каждой реплики выполняются как минимум два ограниченных шага: (A) строгий State Update в JSON и (B) генерация одного следующего вопроса. В конце отдельный Profile Synthesis. Так разговор остаётся человеческим, а факты - проверяемыми.

Минимальные таблицы

Таблица	Что хранит
wellness_interview_sessions	status, mode, started_at, completed_at, prompt_version
wellness_interview_turns	user text/transcript, assistant question, source, confidence
wellness_profile_facts	field, value, source_turn, confidence, confirmed/edited
wellness_narrative_threads	dream_self, obstacles, losses, motivations, open_threads
wellness_completeness	required field, known/missing/deferred, asked_at
wellness_future_self	selfie ref, prompt, model, output ref, accepted/rejected
wellness_scheduled_messages	due_at, type, payload_version, delivered_at, retry_count
wellness_actions / events	offered, accepted, completed, helpful, reason_not_relevant

Не нужен в первые 4 недели: vector DB, LangGraph, отдельные microservices, 8-10 runtime-агентов или custom avatar training.

3. Инструменты и технические решения

Фиксируем не “любимый vendor”, а критерий выбора. Все спорные инструменты сначала проходят маленький benchmark на наших данных.

Слой	MVP choice	Решение
Telegram	Bot API + webhook; текущий backend framework	Voice, photos, documents, buttons. Cloud Bot API скачивает до 20 MB; local Bot API нужен только для больших genome-файлов. [S1]
Speech-to-text	Benchmark: OpenAI gpt-4o-transcribe vs Deepgram Nova-3 Medical	Сравнивать не WER, а accuracy ключевых health-фактов, отрицаний, доз и названий. Оба поддерживают domain prompting/keyterms. [S2-S4]
Interview runtime	Claude Sonnet 5 + strict tool schemas; Pydantic/Zod	Сначала одна сильная модель для State Update и Interviewer. После eval extraction можно перевести на Haiku. [S5]
Context	Postgres state summary + last 4-6 turns	Полный transcript хранится, но каждый turn получает compact state, чтобы не росли cost и drift. Vector DB пока не нужен.
Avatar	Benchmark FLUX.2 Pro vs Gemini 3.1 Flash Image	Identity consistency, same-age, no unwanted beautification/body change. Статичное изображение; animated avatar позже. [S6-S7]
Scheduler	Текущая durable queue; иначе Postgres-backed worker / Cloud Tasks	Нельзя делать sleep(5400) внутри process: reveal должен переживать restart и deploy.
Labs	PyMuPDF → Google Document AI OCR → strict extraction → confirm	Digital PDF без OCR; photo/scan через OCR с quality score. [S8-S10]
Genome	Deterministic parser → Ensembl VEP/ClinVar → curated panel	LLM только объясняет готовую аннотацию; full-genome interpretation не входит в MVP. [S11-S12]
Wearables	Direct WHOOP first + provider adapter; Junction/Terra spike later	Не платить aggregator до доказанного Core WOW. Apple Health/Health Connect потребуют mobile bridge. [S13-S17]
Development	Claude Code: CLAUDE.md + tests + hooks + review subagent	Каждая задача имеет acceptance test “я увидела это в Telegram”. Claude Code умеет project memory, hooks и subagents. [S18-S20]

Прикидка variable cost на completed onboarding

Компонент	Оценка
Voice	15 мин Nova-3 + keyterms ≈ \$0.09; OpenAI измеряем в benchmark.
Interview LLM	Цель \$0.10-\$0.60: зависит от числа turns и compaction; Sonnet 5 тарифицируется по токенам.
Avatar	FLUX.2 Pro image edit от ~\$0.045 за изображение.
OCR	Document AI OCR около \$0.0015 за страницу.
Target	Держать первый complete WOW < \$1/user; считать по реальным traces с Week 1.

Главное решение по voice

Не фиксируем provider “по обзорам”. Во вторник-среду собираем 20-30 внутренних клипов: тихая речь, американские акценты, эмоциональные паузы, мепорause/HRT, лекарства, БАДы и дозы. Побеждает модель с лучшим Critical Fact Recall, а не с самым красивым transcript.

4. Sprint 1 - сокращённая неделя

14-17 июля 2026. Цель: один тонкий end-to-end срез voice/text → context-aware question → structured draft profile. Никаких аватаров и wearables.

День	Фокус	Что должно появиться
Tue 14 Jul	Foundation	CLAUDE.md, architecture decision record, Telegram bot/webhook, allowlist, migrations, event names, smoke test.
Wed 15 Jul	Voice benchmark	20-30 gold clips; OpenAI vs Deepgram; glossary/keyterms; latency/cost logging; выбрать STT adapter.
Thu 16 Jul	Interview engine	State Update schema, completeness map, open_threads, next-question prompt, text fallback, correction path.
Fri 17 Jul	E2E dogfood	3 внутренних пользователя проходят 5-7 turns; profile draft; review logs; fix blocker bugs; sprint demo в Telegram.

Definition of Done

- Voice и text идут в один interview state; пользователь видит transcript и может исправить его до сохранения факта.
- Каждый следующий вопрос явно следует хотя бы одной открытой нити предыдущего ответа, а не очереди заранее записанного quiz.
- Обязательные поля имеют статус known / missing / deferred; система не спрашивает повторно то, что уже услышала.
- На тестовом наборе нет ошибок отрицания ("I do not take..." → "takes") и перепутанных доз; low-confidence факт не становится confirmed.
- После 5-7 turns команда видит structured draft: dream_self, obstacles, health facts, unknowns, open threads.
- Все events и model costs пишутся с первого дня; raw audio и selfie не попадают в application logs.

Что отдать Claude Code в начале

Первая задача

"Не строй весь продукт. Собери один вертикальный срез: Telegram voice → transcript → structured state → один следующий вопрос, который ссылается на предыдущий ответ. 'Готово' означает: я сама прошла 5 turns в Telegram и увидела draft profile. До этого не создавай avatar, labs, wearables или agent council."

Реалистичность: четыре дня достаточно для технического вертикального среза, но недостаточно для "идеального" интервью. Качество вопросов - задача Week 2.

5. Sprint 2-3: интервью и avatar reveal

Сначала добиваемся ощущения “меня поняли”, затем возвращаем пользователю его собственную лучшую версию.

WEEK 2 20-24 Jul	Interview quality + hidden completeness	RISK H
Видимый результат	Пользователь проходит 8-12-turn voice-first интервью, которое звучит как живой разговор и одновременно собирает подтверждаемый health profile.	
Что собираем	• Prompt pack: Interviewer, State Updater, Completeness Checker, Profile Synthesizer, Safety Boundary • Два слоя памяти: factual health profile и narrative profile • Уточняющие вопросы по открытым нитям; не “добывать травму” ради engagement • Confirm / Correct / Skip; базовый crisis/urgent-care route • 20 synthetic scenarios + 5 internal interviews	
Инструменты	• Claude Sonnet 5; strict tool schema • Pydantic/Zod validation • Versioned prompts in repository • Offline evaluator rubric + transcript review	
Готово, когда	• 4/5 тестеров ставят “felt understood” ≥4/5 • ≥90% обязательных полей либо собраны, либо осознанно deferred • Нет повторных/противоречивых вопросов • Correction реально меняет следующий вопрос и итоговый profile	

WEEK 3 27-31 Jul	The You Who Made It: selfie → reveal	RISK H
Видимый результат	Через 60-90 минут после интервью пользователь получает узнаваемый same-age avatar и персональное сообщение от первого лица.	
Что собираем	• Selfie consent + upload + quality check • Avatar brief строится из цели и tone, но не содержит raw medical transcript • Benchmark 10 selfies: FLUX.2 Pro vs Gemini 3.1 Flash Image • Reject / regenerate / choose another photo • Durable scheduled job + retry/idempotency • Message template: recognition → acceptance → realistic promise → evidence transparency	
Инструменты	• FLUX.2 Pro / Gemini 3.1 Flash Image • Object storage with TTL • Postgres scheduled_messages + worker • Image/model/prompt version registry	
Готово, когда	• 4/5 узнают себя и принимают образ • Возраст, этничность и ключевые черты не изменены • Нет автоматического “омоложения на 25 лет” или изменения веса • Reveal приходит в заданном окне даже после restart • Пользователь может удалить selfie/output	

6. Sprint 4-5: 48-hour loop и optional health data

К концу Week 4 уникальная продуктовая гипотеза уже работает без gadgets. Week 5 добавляет данные тем, у кого они есть.

WEEK 4 3-7 Aug	WOW #3: Future You как лучший друг + one NMS action	RISK H
Видимый результат	Примерно через 48 часов Future You возвращается не как alarm, а как голос самого пользователя: принимает контекст и предлагает одно мягкое действие.	
Что собираем	• Tone profile из интервью: direct/warm, preferred name, sensitive themes, shame triggers • 48h message: acknowledgement → permission → one action → why this • Curated NMS set 20-30 practices: walking, feet, first light, sleep, mobility, breath • Rules: 3/7/12 min, no athlete language, no 8,000-step default • Done / Later / Not today / Not for me • Action outcome меняет следующий message	
Инструменты	• Existing NMS catalog + deterministic metadata mapping • Claude message generator with bounded template • Durable scheduler • Event analytics	
Готово, когда	• Сообщение содержит реальный контекст, но не звучит сгееру или как дословный пересказ травмы • ≥3/5 отвечают или принимают action • Action соответствует ограничениям и не требует перестроить жизнь • Пропуск уменьшает следующий шаг, а не вызывает guilt	

WEEK 5 10-14 Aug	Optional health-data intake v1	RISK H
Видимый результат	Пользователь может просто прислать lab PDF/photo, voice/photo текущего stack и, как stretch, genome file; profile становится точнее, но опыт не блокируется без данных.	
Что собираем	• Digital PDF → text; scan/photo → OCR • Strict lab schema: test, value, unit, range, date, confidence, raw line • Stack: substance, dose, timing, reason, prescriber → confirm • Genome: format detection + curated 20-30 variants only (stretch) • Every fact: source + confidence + Confirm/Edit/Reject • Suggested missing tests - только как topic to discuss with clinician	
Инструменты	• PyMuPDF • Google Document AI OCR + quality score • Claude strict extraction • Deterministic genome parser + Ensembl VEP/ClinVar • Telegram file intake; local Bot API only if >20 MB	
Готово, когда	• 3 разных lab-документа проходят без silent decimal/unit error • Low-confidence never enters active profile without confirmation • Stack можно исправить voice/text • Genome не является gate недели; ship only if curated panel reliable	

7. Sprint 6-7: wearables и evidence-backed agents

Data layer усиливает уже эмоционально работающий companion. Пользователь без device по-прежнему получает полный core experience.

WEEK 6 17-21 Aug	Wearable Gateway v1 + data-aware proactivity	RISK H
Видимый результат	Один внутренний тестер подключает WHOOP; Future You использует реальные sleep/recovery данные, но переводит их в мягкий режим дня, а не athlete score.	
Что собираем	• Provider adapter interface + normalized schema • Direct WHOOP OAuth, backfill, v2 webhooks, idempotency, freshness • Fields: sleep, HRV, RHR, recovery, strain/activity • Source/timestamp visible; stale data blocks conclusion • 1-day commercial spike: Junction vs Terra for future providers • Apple Health/Health Connect remain future mobile bridge	
Инструменты	• WHOOP API + webhooks • Current backend endpoint + scheduler • Normalized daily_metrics • Junction/Terra comparison, no commitment yet	
Готово, когда	• Real WHOOP data visible in Telegram • Repeat webhook creates no duplicate • One proactive message uses real data and a personal-context action • No wearable = self-report fallback, not broken flow	

WEEK 7 24-28 Aug	Specialist agents + evidence + doctor handoff	RISK H
Видимый результат	Для high-impact вопроса система формирует одну объяснимую гипотезу, показывает missing data и готовит clinician-ready summary.	
Что собираем	• Relevant roles only: Women 50+, Men's Vitality, Family, Labs/Genome, Supplements/Peptides, Safety • Round A independent views; Round B only for conflict/high impact • Coordinator returns one finding, one uncertainty, one next step • PubMed evidence tool + strength label • Candidate supplement/peptide hypothesis; no autonomous start/dose • Manual doctor approve / modify / reject	
Инструменты	• Claude tool use with strict schemas • PubMed E-utilities • Versioned agent prompts • Simple admin page or Telegram clinician buttons • Protocols / agent_reports in Postgres	
Готово, когда	• Один internal case проходит: data → hypothesis → objections → coordinator → clinician decision • Решение врача меняет state • Нет сообщения "начните принимать" без human gate • User-facing output помещается в один экран	

8. Sprint 8: замкнутый цикл, качество и решение о следующем этапе

31 августа - 4 сентября. Не добавляем новую "магическую" функцию; доказываем, что система запоминает, адаптируется и выдерживает сбои.

WEEK 8 31 Aug-4 Sep	Action → data → conclusion + hardening	RISK M
Видимый результат	Пользователь видит, что Nila/Future You изменила следующий шаг на основании его поведения, feedback и доступных данных.	
Что собираем	• State lifecycle: offered → accepted → started → completed/stopped • Feedback: helped / unclear / did not help + context change • Pre/post windows for wearable/labs where available • Prompt/model/version registry; cost dashboard • Retry, idempotency, quiet hours, alert cap, deletion/export • 48-hour removal test + sprint review	
Инструменты	• Postgres events/protocols/checkins • Deterministic comparisons; no causal claim from one day • Sentry/monitoring + automated tests • Claude Code hooks: tests/lint/type-check before completion	
Готово, когда	• Core WOW flow survives restart and retries • Future message changes after correction/action outcome • No critical data extraction errors in golden set • Team can name a concrete loss during removal test • Go/No-Go decision documented with evidence	

North-star и gates

Метрика	Gate
Interview completion	≥70% internal invitees finish; secondary at MVP scale
Felt understood	≥4/5 у 4 из 5 тестеров
Critical fact accuracy	No negation/dose/age errors in golden set; corrections tracked
Avatar acceptance	≥4 из 5 recognize/accept; no unwanted age/identity shift
90-minute reveal	Delivered on time; ≥60% open/reply in team test
48-hour value	≥3 из 5 reply, accept action or explicitly call it useful
Health-data quality	No unconfirmed low-confidence fact in active profile
Removal pain	Минимум 2 тестера называют конкретную потерянную пользу

Как интерпретировать маленькую выборку

3-5 внутренних тестеров не дают статистического доказательства. Эти gates нужны, чтобы находить blocker issues и принимать product decision, а не объявлять retention победой. После Week 4 нужен отдельный moderated test с 5-8 женщинами 50+.

9. Как вести разработку в Claude Code

План рассчитан на одного основного builder при наличии текущего backend/DB. AI пишет код быстро; качество создают scope, tests и наблюдаемая приёмка.

Project setup в первый день

- Корневой CLAUDE.md до 200 строк: архитектура, команды, data rules, “done = я увидела в Telegram”, запрет PII/raw health data в логах.
- .claude/settings.json: разрешённые команды, hooks на tests/lint/type-check; secrets только в local settings/secret manager.
- Три developer subagents: reviewer, test-writer, privacy/data-flow checker. Это помощники разработки, не runtime wellness-agents.
- Каждая user story заканчивается E2E демо и сохранённым trace; Claude Code не получает следующую неделю как один огромный prompt.
- Отдельный golden dataset: voice clips, interview transcripts, lab pages, selfies; versioned expected outputs и regression tests.

Ресурсная оценка

Ресурс	Минимум
Основной builder	1 FTE, Claude Code, 8 недель
Product/UX/content	0.3-0.5 FTE; особенно Weeks 2-4
Medical reviewer	2-4 h/week с Week 5; обязательный с Week 7
Internal testers	3-5 человек; 2 full interviews/week
Target users	5-8 moderated sessions после Core WOW MVP
Если backend/DB нет	Добавить 1 foundation week до Sprint 1

Источники

S1 Telegram Bot API: voice/documents, 20 MB cloud download, local server, message deletion	S2 OpenAI Speech-to-Text: gpt-4o-transcribe, prompts, logprobs, 25 MB
S3 Deepgram Nova-3 Medical / model options	S4 Deepgram keyterm prompting and pricing
S5 Anthropic strict tool use / structured tool calls	S6 Black Forest Labs FLUX.2 identity-preserving multi-reference editing
S7 Gemini image generation / character consistency	S8 PyMuPDF text and table extraction
S9 Google Document AI Enterprise OCR	S10 Google Document AI pricing
S11 Ensembl Variant Effect Predictor	S12 NCBI ClinVar
S13 WHOOP API	S14 WHOOP webhooks
S15 Junction supported wearable providers	S16 Terra supported data sources / mobile-only limits
S17 Apple HealthKit authorization	S18 Claude Code project memory / CLAUDE.md
S19 Claude Code subagents	S20 Claude Code hooks
S21 Anthropic model pricing	S22 Black Forest Labs pricing
S23 Deepgram pricing	

Основание для переработки: приложенный 6-недельный план v0.1, BLUEPRINT и PLAYBOOK. В v0.2 изменён порядок: interview → Future You → 48h loop становятся основой продукта; health-data layers переносятся после доказательства Core WOW.